

Deep Reinforcement Learning

4A – IABD – Intro

Spoiler

- Livre au top :
 - <http://incompleteideas.net/book/the-book.html>
- Un cours sur Coursera qui suit le livre (très bonne qualité):
 - <https://www.coursera.org/specializations/reinforcement-learning>
- Cours dispensé à Stanford :
 - <https://www.youtube.com/watch?v=FgzM3zpZ55o&list=PLoROMvodv4rOSOPzutgyCTapiGIY2Nd8u>
- Intro dispensée par DeepMind :
 - <https://www.youtube.com/watch?v=TCCjZe0y4Qc&list=PLqYmG7hTraZDVH599EItlEWsUOsJbAodm>

Markov Decision Process




Figure 3.1: The agent–environment interaction in a Markov decision process.

Markov Decision Process

- Ensemble d'Action : A
- Ensemble d'Etats : S
- Ensemble de Récompenses immédiates : R




Figure 3.1: The agent–environment interaction in a Markov decision process.

Markov Decision Process

- Ensemble d'Action : A
- Ensemble d'Etats : S
- Ensemble de Récompenses immédiates : R
- Hypothèse : S_{t+1} et R_{t+1} ne dependent que de S_t et de A_t




Figure 3.1: The agent–environment interaction in a Markov decision process.

Markov Decision Process

- Ensemble d'Action : A
- Ensemble d'Etats : S
- Ensemble de Récompenses immédiates : R
- Hypothèse : S_{t+1} et R_{t+1} ne dependent que de S_t et de A_t
- On parle d'hypothèse Markovienne




Figure 3.1: The agent–environment interaction in a Markov decision process.

Markov Decision Process

- Ensemble d'Action : A
- Ensemble d'Etats : S
- Ensemble de Récompenses immédiates : R
- Hypothèse : S_{t+1} et R_{t+1} ne dependent que de S_t et de A_t
- On parle d'hypothèse Markovienne
- On suppose l'existence de :
 - $p(s', r|s, a)$
 - (Environment dynamics)




Figure 3.1: The agent–environment interaction in a Markov decision process.

Markov Decision Process

- Ensemble d'Action : A
- Ensemble d'Etats : S
- Ensemble de Récompenses immédiates : R
- Hypothèse : S_{t+1} et R_{t+1} ne dependent que de S_t et de A_t
- On parle d'hypothèse Markovienne
- On suppose l'existence de :
 - $p(s', r | s, a)$
 - (Environment dynamics)
 - Il s'agit de la probabilité d'obtenir l'état s' et la recompense r à partir de l'état s en effectuant l'action a




Figure 3.1: The agent–environment interaction in a Markov decision process.

Markov Decision Process

- On suppose l'existence de :
 - $p(s', r|s, a)$
 - (Environment dynamics)
 - Il s'agit de la probabilité d'obtenir l'état s' et la recompense r à partir de l'état s en effectuant l'action a
- Ainsi :

$$\sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r|s, a) = 1, \text{ for all } s \in \mathcal{S}, a \in \mathcal{A}(s). \quad (3.3)$$




Figure 3.1: The agent–environment interaction in a Markov decision process.

Quel est le but de l'Agent dans ce contexte ?

- Deux cas de figures :
 - Tâches épisodiques
 - Tâches continues




Figure 3.1: The agent–environment interaction in a Markov decision process.

Quel est le but de l'Agent dans ce contexte ?

- Deux cas de figures :
 - Tâches épisodiques
 - L'agent est certain de se retrouver dans une situation terminale tôt ou tard
 - Tâches continues
 - Il n'y a pas de situation terminale




Figure 3.1: The agent–environment interaction in a Markov decision process.

Quel est le but de l'Agent dans ce contexte ?

- Deux cas de figures :
 - Tâches épisodiques
 - L'agent est certain de se retrouver dans une situation terminale tôt ou tard
 - Tâches continues
 - Il n'y a pas de situation terminale
- Le but (Goal) de l'agent est de maximiser sa récompense cumulée long terme

- $G_t \doteq R_{t+1} + R_{t+2} + R_{t+3} + \dots + R_T,$ (3.7)

- $G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1},$ (3.8)

Quel est le but de l'Agent dans ce contexte ? γ

- Deux cas de figures :

-  Tâches épisodiques
 - L'agent est certain de se retrouver dans une situation terminale tôt ou tard

-  Tâches continues
 - Il n'y a pas de situation terminale

- Le but (Goal) de l'agent est de maximiser sa récompense cumulée long terme

-  $G_t \doteq R_{t+1} + R_{t+2} + R_{t+3} + \dots + R_T,$ (3.7)

-  $G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1},$ (3.8)

Quel est le but de l'Agent dans ce contexte ?

- Le but (Goal) de l'agent est de maximiser sa récompense cumulée long terme :



- $G_t \doteq R_{t+1} + R_{t+2} + R_{t+3} + \cdots + R_T,$ (3.7)



- $G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1},$ (3.8)

- On remarque :

- $G_t = R_{t+1} + \gamma G_{t+1}$

- $G_t \doteq \sum_{k=t+1}^T \gamma^{k-t-1} R_k$

Comment y parvenir ?

- Notations :

- « policy »

- $\pi(a|s)$

- Renvoyant la probabilité de réaliser l'action a dans un état s

- « value function »

- $v_{\pi}(s)$

- Renvoyant la moyenne (espérance) de la récompense long terme cumulée à partir de l'état s en suivant la stratégie π

- « action-value function »

- $q_{\pi}(s, a)$

- Renvoyant la moyenne (espérance) de la récompense long terme cumulée à partir de l'état s en effectuant l'action a puis en suivant la stratégie π à partir de l'état suivant

Comment y parvenir ?

- Notations :

- « policy »

- $\pi(a|s)$

- Renvoyant la probabilité de réaliser l'action a dans un état s

- « value function »

- $v_\pi(s)$

$$v_\pi(s) \doteq \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s \right], \text{ for all } s \in \mathcal{S}, \quad (3.12)$$

- Renvoyant la moyenne (espérance) de la récompense long terme cumulée à partir de l'état s en suivant la stratégie π

- « action-value function »

- $q_\pi(s, a)$

$$q_\pi(s, a) \doteq \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right]. \quad (3.13)$$

- Renvoyant la moyenne (espérance) de la récompense long terme cumulée à partir de l'état s en effectuant l'action a puis en suivant la stratégie π à partir de l'état suivant

Comment y parvenir ?

- Nous pouvons réécrire $v_\pi(s)$:

$$\begin{aligned} v_\pi(s) &\doteq \mathbb{E}_\pi[G_t \mid S_t = s] \\ &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) \left[r + \gamma \mathbb{E}_\pi[G_{t+1} | S_{t+1} = s'] \right] \\ &= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_\pi(s') \right], \quad \text{for all } s \in \mathcal{S}, \end{aligned}$$

- Il s'agit d'une des équations de Bellman !

Comment y parvenir ?

- Nous pouvons réécrire $v_\pi(s)$:

$$\begin{aligned} v_\pi(s) &\doteq \mathbb{E}_\pi[G_t \mid S_t = s] \\ &= \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s'} \sum_r p(s', r | s, a) \left[r + \gamma \mathbb{E}_\pi[G_{t+1} | S_{t+1} = s'] \right] \\ &= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_\pi(s') \right], \quad \text{for all } s \in \mathcal{S}, \end{aligned}$$

- Il s'agit d'une des équations de Bellman !
- Tentons d'évaluer la « value function » d'une « policy » uniformément aléatoire sur un exemple jouet => « Policy Evaluation »

Comment y parvenir ?

- Tentons d'évaluer la « value function » d'une « policy » uniformément aléatoire sur un exemple jouet
 - « Policy Evaluation »
- On parle de tâche de « Prediction »
- Répéter (pour $k = 0..$) jusqu'à convergence et pour tous les s :

$$\begin{aligned} v_{k+1}(s) &\doteq \mathbb{E}_{\pi}[R_{t+1} + \gamma v_k(S_{t+1}) \mid S_t = s] \\ &= \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) [r + \gamma v_k(s')], \end{aligned} \tag{4.5}$$

Comment y parvenir ?

- Pseudo code pour évaluer une stratégie a.k.a « Policy Evaluation » :

Iterative Policy Evaluation, for estimating $V \approx v_\pi$

Input π , the policy to be evaluated

Algorithm parameter: a small threshold $\theta > 0$ determining accuracy of estimation

Initialize $V(s)$, for all $s \in \mathcal{S}^+$, arbitrarily except that $V(\text{terminal}) = 0$

Loop:

$\Delta \leftarrow 0$

Loop for each $s \in \mathcal{S}$:

$v \leftarrow V(s)$

$V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma V(s')]$

$\Delta \leftarrow \max(\Delta, |v - V(s)|)$

until $\Delta < \theta$

Comment y parvenir ?

- Ne perdons pas de vue l'objectif !
 - Trouver la meilleure des « policies » ! (a.k.a. celle qui maximise en moyenne le reward long terme cumulé)

Comment y parvenir ?

- Ne perdons pas de vue l'objectif !
 - Trouver la meilleure des « policies » ! (a.k.a. celle qui maximise en moyenne le reward long terme cumulé)
 - Notons ces ou cette stratégie π_*
 - Il peut y en avoir plusieurs !
 - Exemple

Comment y parvenir ?

- Ne perdons pas de vue l'objectif !
 - Trouver la meilleure des « policies » ! (a.k.a. celle qui maximise en moyenne le reward long terme cumulé)
 - On parle de tâche de « Control »
 - Notons ces ou cette stratégies π_*
 - Il peut y en avoir plusieurs !
 - Exemple
 - Cependant, elles ont toutes la même « value function » optimale associée
 - Notons cette dernière v_*

Comment y parvenir ?

- Ne perdons pas de vue l'objectif !
 - Trouver la meilleure des « politiques » ! (a.k.a. celle qui maximise en moyenne le reward long terme cumulé)
 - On parle de tâche de « Control »
 - Notons ces ou cette stratégies π_*
 - Il peut y en avoir plusieurs !
 - Exemple
 - Cependant, elles ont toutes la même « value function » optimale associée
 - Notons cette dernière v_*
- En effet :
 - $v_*(s) \doteq \max_{\pi} v_{\pi}(s),$ (3.15)

Comment y parvenir ?

- Cependant, elles ont toutes la même « value function » optimale associée
 - Notons cette dernière v_*
- En effet :
 - $v_*(s) \doteq \max_{\pi} v_{\pi}(s),$ (3.15)
- Il en va de même pour l' « action-value function » optimale
 - Notons cette dernière q_*
- En effet :
 - $q_*(s, a) \doteq \max_{\pi} q_{\pi}(s, a),$ (3.16)

Comment y parvenir ?

- Si l'on trouve v_* et que l'on connaît $p(s', r | s, a)$ alors nous pouvons en déduire une des π_* !
- Si l'on trouve q_* alors nous pouvons en déduire une des π_* !
- Comment trouver v_* ou q_* ?

Comment y parvenir ?

- Partons de deux des équations d'optimalité de Bellman :

$$\begin{aligned}v_*(s) &= \max_{a \in \mathcal{A}(s)} q_{\pi_*}(s, a) \\&= \max_a \mathbb{E}_{\pi_*}[G_t \mid S_t = s, A_t = a] \\&= \max_a \mathbb{E}_{\pi_*}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] \\&= \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a] \\&= \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_*(s')].\end{aligned}$$

$$\begin{aligned}q_*(s, a) &= \mathbb{E}\left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a\right] \\&= \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \max_{a'} q_*(s', a')\right].\end{aligned}$$

Comment y parvenir ?

- Pseudo code pour évaluer puis améliorer en boucle une stratégie a.k.a. « Policy Iteration »:

Policy Iteration (using iterative policy evaluation) for estimating $\pi \approx \pi_*$

1. Initialization

$V(s) \in \mathbb{R}$ and $\pi(s) \in \mathcal{A}(s)$ arbitrarily for all $s \in \mathcal{S}$

2. Policy Evaluation

Loop:

$\Delta \leftarrow 0$

Loop for each $s \in \mathcal{S}$:

$v \leftarrow V(s)$

$V(s) \leftarrow \sum_{s',r} p(s',r|s,\pi(s)) [r + \gamma V(s')]$

$\Delta \leftarrow \max(\Delta, |v - V(s)|)$

until $\Delta < \theta$ (a small positive number determining the accuracy of estimation)

3. Policy Improvement

policy-stable $\leftarrow$ true

For each $s \in \mathcal{S}$:

old-action $\leftarrow \pi(s)$

$\pi(s) \leftarrow \operatorname{argmax}_a \sum_{s',r} p(s',r|s,a) [r + \gamma V(s')]$

If *old-action* $\neq \pi(s)$, then *policy-stable* $\leftarrow$ false

If *policy-stable*, then stop and return $V \approx v_*$ and $\pi \approx \pi_*$; else go to 2

Comment y parvenir ?

- Nous pouvons être plus rapide en itérant directement sur v a.k.a. « Value Iteration »:

Value Iteration, for estimating $\pi \approx \pi_*$

Algorithm parameter: a small threshold $\theta > 0$ determining accuracy of estimation
Initialize $V(s)$, for all $s \in \mathcal{S}^+$, arbitrarily except that $V(\text{terminal}) = 0$

Loop:

```
|  $\Delta \leftarrow 0$   
| Loop for each  $s \in \mathcal{S}$ :  
|    $v \leftarrow V(s)$   
|    $V(s) \leftarrow \max_a \sum_{s',r} p(s',r|s,a) [r + \gamma V(s')]$   
|    $\Delta \leftarrow \max(\Delta, |v - V(s)|)$   
until  $\Delta < \theta$ 
```

Output a deterministic policy, $\pi \approx \pi_*$, such that

$$\pi(s) = \operatorname{argmax}_a \sum_{s',r} p(s',r|s,a) [r + \gamma V(s')]$$

Et si l'on n'a pas de modèle ?

- Première hypothèse :
 - Cas épisodique
- Techniques dites de Monte Carlo
 - a.k.a faisons plein de tests !

Et si l'on n'a pas de modèle ?

- Monte Carlo Prediction :

First-visit MC prediction, for estimating $V \approx v_\pi$

Input: a policy π to be evaluated

Initialize:

$V(s) \in \mathbb{R}$, arbitrarily, for all $s \in \mathcal{S}$

$Returns(s) \leftarrow$ an empty list, for all $s \in \mathcal{S}$

Loop forever (for each episode):

Generate an episode following π : $S_0, A_0, R_1, S_1, A_1, R_2, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Unless S_t appears in $S_0, S_1, \dots, S_{t-1}$:

Append G to $Returns(S_t)$

$V(S_t) \leftarrow \text{average}(Returns(S_t))$

Et si l'on n'a pas de modèle ?

- Mais si nous n'avons pas de modèle, nous préférons obtenir q plutôt que v , pour pouvoir améliorer π !
- Problématique de l'exploration ...
- Si nous pouvons démarrer dans un état aléatoire et jouer une action aléatoire alors ...

Et si l'on n'a pas de modèle ?

- Mais si nous n'avons pas de modèle, nous préférons obtenir q plutôt que v , pour pouvoir améliorer π !

Monte Carlo ES (Exploring Starts), for estimating $\pi \approx \pi_*$

Initialize:

$\pi(s) \in \mathcal{A}(s)$ (arbitrarily), for all $s \in \mathcal{S}$

$Q(s, a) \in \mathbb{R}$ (arbitrarily), for all $s \in \mathcal{S}, a \in \mathcal{A}(s)$

$Returns(s, a) \leftarrow$ empty list, for all $s \in \mathcal{S}, a \in \mathcal{A}(s)$

Loop forever (for each episode):

Choose $S_0 \in \mathcal{S}, A_0 \in \mathcal{A}(S_0)$ randomly such that all pairs have probability > 0

Generate an episode from S_0, A_0 , following π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}$:

Append G to $Returns(S_t, A_t)$

$Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$

$\pi(S_t) \leftarrow \arg \max_a Q(S_t, a)$

Et si l'on n'a pas de modèle ?

- Mais si nous n'avons pas de modèle, nous préférons obtenir q plutôt que v , pour pouvoir améliorer π !
- Problématique de l'exploration ...
- Sinon nous pouvons utiliser une stratégie dite « ε -greedy » ...

Et si l'on n'a pas de modèle ?

- Mais si nous n'avons pas de modèle, nous préférons obtenir q plutôt que v , pour pouvoir améliorer π !

On-policy first-visit MC control (for ε -soft policies), estimates $\pi \approx \pi_*$

Algorithm parameter: small $\varepsilon > 0$

Initialize:

$\pi \leftarrow$ an arbitrary ε -soft policy

$Q(s, a) \in \mathbb{R}$ (arbitrarily), for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

$Returns(s, a) \leftarrow$ empty list, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$

Repeat forever (for each episode):

Generate an episode following π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}$:

Append G to $Returns(S_t, A_t)$

$Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$

$A^* \leftarrow \arg\max_a Q(S_t, a)$ (with ties broken arbitrarily)

For all $a \in \mathcal{A}(S_t)$:

$$\pi(a|S_t) \leftarrow \begin{cases} 1 - \varepsilon + \varepsilon/|\mathcal{A}(S_t)| & \text{if } a = A^* \\ \varepsilon/|\mathcal{A}(S_t)| & \text{if } a \neq A^* \end{cases}$$

Et si l'on n'a pas de modèle ?

- Mais si nous n'avons pas de modèle, nous préférons obtenir q plutôt que v , pour pouvoir améliorer π !
- Attention, nous n'apprenons plus q_* !

Et si l'on n'a pas de modèle ?

Off-policy MC control, for estimating $\pi \approx \pi_*$

Initialize, for all $s \in \mathcal{S}$, $a \in \mathcal{A}(s)$:

$Q(s, a) \in \mathbb{R}$ (arbitrarily)

$C(s, a) \leftarrow 0$

$\pi(s) \leftarrow \operatorname{argmax}_a Q(s, a)$ (with ties broken consistently)

Loop forever (for each episode):

$b \leftarrow$ any soft policy

Generate an episode using b : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

$W \leftarrow 1$

Loop for each step of episode, $t = T-1, T-2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

$C(S_t, A_t) \leftarrow C(S_t, A_t) + W$

$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \frac{W}{C(S_t, A_t)} [G - Q(S_t, A_t)]$

$\pi(S_t) \leftarrow \operatorname{argmax}_a Q(S_t, a)$ (with ties broken consistently)

If $A_t \neq \pi(S_t)$ then exit inner Loop (proceed to next episode)

$W \leftarrow W \frac{1}{b(A_t|S_t)}$